# Projeto Final

## Problema:

Website de classificados (de uso gratuito) com elevado número de pedidos de apoio ao cliente a requerer resposta manual por parte da equipa encarregue. Vários destes pedidos já estarão ponderados e descritos na página do website dedicada a FAQ's (Frequently Asked Questions).

## Utilizador:

Os pedidos de apoio ao cliente podem originar de utilizadores com os seguintes perfis:

- Comprador - Pesquisa por anúncios de outros utilizadores. Pode ou não entrar em contacto com os mesmos para comprar/negociar;
- Vendedor - Publica anúncios. Pode ser contactado por outros utilizadores interessados. Pode ainda comprar serviços para destacar/promover os seus anúncios.

## Solução:

Implementação de um chat-bot embedded no próprio website, com o objetivo de dar resposta a todos os pedidos cuja resposta/solução se encontra descrita na página dedicada de FAQ's do website.

Adicionalmente, no caso de ser incapaz de indicar uma FAQ que dê resposta ao pedido, deverá solicitar informação adicional ao utilizador, ou indicar o link para o formulário de pedido de apoio ao cliente mais relevante (ex: "Problemas com anúncios", ou "Problemas técnicos", etc.)

# Detalhes:

1. Antes de  proceder ao embedding da mensagem do utilizador, será sempre feita uma pré-validação da mesma, de modo a validar se é uma pergunta válida (é mesmo uma pergunta? Tópicos válidos? etc.). Isto será feito através duma chamada a um LLM, com structured output configurado para o efeito pretendido. Esta medida tem como objetivo prevenir o uso de recursos em processos de embedding + RAG desnecessários;
2. De modo a ter acesso à lista de FAQ's do website, o chat-bot irá recorrer a RAG, mantendo uma base de dados vectorial das mesmas. Estas FAQ's encontram-se "hard-coded" no front-end do website, logo, apenas podem ser alteradas após um novo deploy do mesmo. A ideia será realizar um scraping ao website para popular a BD vetorial. Em todas as instâncias de RAG, será consultada a meta tag "version" do website para detectar quando estamos perante um novo build (com possivelmente novas FAQ's). Caso seja esse o caso, a base de dados vetorial será repopulada com as FAQ's atuais.

   **NOTA:** Atualmente ainda não foi possível determinar se haveria algum ganho de performance com a introdução de um "passo-extra", onde se validaria se as FAQ's do novo build são efetivamente diferentes das que foram usadas para gerar os embeddings atualmente armazenados na BD.
3. A estratégia de chunking adotada será uma de "Document-Aware Structural Chunking", onde cada chunk irá corresponder a uma FAQ (com a pergunta + respetiva resposta). Atualmente o texto de cada FAQ é relativamente breve, e como tal, julgo não ser necessário ponderar "sub-chunking" do mesmo. No entanto, seria bom para termos de future-proofing;
4. Em termos de gestão de contexto/histórico da conversa: Planeia-se manter um histórico da conversa atual composto pela mensagem inicial + as últimas X trocas de mensagens; No caso da conversa exceder X trocas de mensagens, será gerado um resumo do contexto atual (recorrendo a LLM), de modo a obter a resultante estrutura para o novo contexto:

   [1ª mensagem + resumo da 2ª troca mensagem até à penúltima troca de mensagens mais recente + troca de mensagens mais recentes].

   No entanto, devido à função do chat-bot, isto deverá ser uma ocorrência rara.

# Schemas de Structured Output planeados:

1. Pré-validação do pedido:
    - is_valid_question (BOOLEAN)
    - suggested_response (STRING)
2. Chamada com resultados RAG:
    - sources (LIST[SearchResult])
    - topics (LIST[String])
    - confidence_score (LITERAL["low","medium","high"])
    - Missing_info (LIST[String])
    - Relevant_contact_form (LITERAL[...])
    - suggested_response (STRING)